



学术汇报

我对世界模型 的理解

从行为认知出发，理解三条技术路线

汇报人：_____

时间：2026 年 9 月


像素派 · 潜空间派 · 三维显式派 · LLM



从一个行为开始：走出房间

从起身到开门，我们一直在根据观测调整动作。

行为认知



眼前场景与身体感受，构成行动的观测信息

观测 → 动作。为什么偏偏选择这个动作？

脚的朝向

根据眼前的场景和门的位置调整

左右脚的重心

根据身体姿态和承重情况分配

手的启动时机


根据与门的距离决定何时伸手

为什么选择这个动作，而不是另一个？

可以把这个过程理解为：先想象不同动作的结果，再做选择。

行为认知

当前观测相同



目标：伸手接近门把手

手不移动



模拟这一动作

可能的未来 ①

0.5 m/s



模拟这一动作

可能的未来 ②

0.4 m/s



模拟这一动作

可能的未来 ③

0.2 m/s



模拟这一动作

可能的未来 ④

比较候选动作对应的未来，再选出更合适的动作。



这就需要 一个“内部模拟器”

我的理解：世界模型用来回答“如果这样做，接下来会发生什么？”

核心思想




观测 + 候选动作 → 推演未来 → 选择动作。

我的分类：像素派、潜空间派、三维显式派

不同综述有不同分类；结合自己的学习，我按“未来怎样表示”来理解。

我的分类


像素派



用未来图像／视频

呈现推演结果


潜空间派



把观测编码成特征

在特征空间推演

三维显式派



先构建三维世界


再更新空间状态

三条路线，共同回答：给定观测和动作，未来会怎样？

像素派：用视频生成模拟未来

把熟悉的视频生成模型，变成“观测+动作 → 未来帧”的模拟器。

01 像素派



用前面的帧作为观测，生成下一帧或后续片段

观测 + 动作 → 下一帧；继续推演，就得到一段未来视频。



像素派如何训练？先学视频，再对齐机器人动作

一条常见路径：无动作视频预训练 → 带动作交互数据微调。

01 像素派

01 视频预训练

互联网／其他无动作标签视频

利用前后帧学习视觉变化
获得一般的运动与场景知识
不要求每段视频都有机器人动作



02 机器人数据微调

观测 + 动作 + 后续观测

使用特定机器人的交互轨迹
把控制参数与视觉后果对齐
学习“执行这个动作会怎样”

先学习世界怎样变化，再学习这台机器人的动作会怎样改变世界。



像素派：五个代表方法

它们都用视频表达未来，但动作条件和训练数据的来源不同。

01 像素派

方法／年份	动作条件	预测结果	训练数据路径
UniSim · 2024	语言动作／低层控制	未来交互视频	机器人、人类视频与互联网等混合数据
iVideoGPT · 2024	数值动作	未来视觉 token ／ 视频	OXE + SSv2 无动作预训练，再适配
Genie · 2024	离散潜在动作	可操控的未来画面	无真实动作标签的互联网游戏视频
AdaWorld · 2025	连续潜在动作	动作条件未来视频	从混合视频提取动作表示，再适配
Vid2World · 2025	真实动作条件	连续交互视频	继承视频预训练，再用领域动作轨迹

视频生成的能力，经过动作条件训练，可以用于模拟交互后的未来。



潜空间派：不必把未来逐像素画出来

杨立昆相关路线：把观测变成特征，重点预测与未来有关的信息。

02 潜空间派

模拟时，关注什么？

走向门把手时，可以关注：
距离、身体姿态、手的运动
而不必设想墙面每一处纹理。

这对应怎样的模型？


把观测编码成潜在特征
结合候选动作预测下一特征
推演主体留在特征空间中。

思想上延续 2018 年《World Models》：用内部表征模拟未来。

潜空间派：观测编码后，在特征空间持续推演

当前潜状态+动作 → 下一个潜状态；再把预测结果接着往后推。

02 潜空间派



推演不必每一步都生成图像，而是持续更新内部的潜在特征。



潜空间派：五个代表方法

从 2018 年的潜状态建模，走向预训练视觉特征上的未来预测。

02 潜空间派

方法／年份	怎样表示世界	怎样推演未来
World Models · 2018	VAE 潜变量 + RNN 记忆	在潜空间预测下一状态分布
PlaNet · 2019	确定性与随机潜状态	用 RSSM 展开多步预测
Dreamer · 2020	RSSM 潜状态	在潜空间想象未来并学习行为
DINO-WM · 2025	冻结的 DINOv2 空间特征	用动作条件 Transformer 预测后续特征
V-JEPA 2-AC · 2025	视频预训练视觉特征	后训练加入动作条件，预测未来特征

共同点：先用内部表征描述世界，再学习它在动作作用下怎样变化。



三维显式派：先把“同一个世界”建立起来

我对李飞飞空间智能路线的理解：把世界的表示与后续推演分开。

03 三维显式派

一边生成画面，一边组织场景与变化

观测 + 动作

当前画面与控制条件



同时建模场景与变化

在生成过程中维持一致性



后续画面

场景可能发生漂移

先建立三维世界，再让动作改变其中的状态

观测

先认识当前场景



一致的三维表示

同一房间、同一物体



动作推演

更新应当变化的状态

先把世界表征出来，再让机器人在这个世界里模拟动作。



三维显式派：先构建世界，再模拟、再渲染

观测 → 三维表示 → 动作推演 → 未来观测。

03 三维显式派



三维状态随动作更新；渲染负责把这个状态显示为观测。



三维显式派：五个代表方法与产品

从开放的三维动态研究，到 World Labs 的闭源世界生成产品。

03 三维显式派

方法／年份	开放形式	三维表示与核心作用
ManiGaussian · 2024	代码公开	使用动态 Gaussian 场景，学习动作条件下的变化
DreMa · 2025	代码公开	结合 Gaussian 场景与物理仿真，生成机器人示范
PointWorld · 2026	代码公开	根据 RGB-D 与机器人动作，预测场景三维点运动
Marble · 2025	闭源产品／API	从文本、图像等生成可编辑的三维世界
Atlas · 2026	官方预览／未公开权重	融合图像、视频与三维信息，组织共享空间上下文

前三项是开放研究案例；后两项是 World Labs 产品／预览。



LLM 属不属于世界模型？我的看法：可以

关键不只在架构，也在训练数据、训练目标，以及未来状态的表达方式。

04 LLM

当前状态（语言）

门关闭，且未上锁

给定动作（语言）

转动门把手并推门

下一状态（语言）

门打开，通道可通过

模型架构

LLM 可以作为
状态转移预测的骨干

训练数据

用“状态+动作→后果”
这类样本进行任务微调

输出状态

未来不一定是图像
也可以用语言或符号描述

换一种训练任务和状态表示，LLM 也可以承担世界模型的功能。



我的理解：同样在推演，只是未来的表示不同

从走出房间的例子出发，把几条路线放回同一个问题中。

总结

路线	怎样处理当前观测	动作怎样参与	未来怎样表示
像素派	把前面帧作为视觉上下文	作为视频预测条件	下一帧／未来视频
潜空间派	先编码为潜在特征	与潜状态一起预测	下一个潜在特征
三维显式派	先构建三维世界	驱动三维状态更新	未来三维状态／渲染
LLM（补充理解）	用语言或符号描述状态	作为状态转移条件	下一语言／符号状态

先想清楚“这样做会怎样”，再决定“应该怎么做”。



参考资料 1/2



正文页脚编号对应本页；演讲者备注附有完整来源。

- | | | | |
|-----------|--|-----------|---|
| 01 | Ha & Schmidhuber. World Models. 2018.

worldmodels.github.io/ | 06 | Gao et al. AdaWorld: Learning Adaptable World Models with Latent Actions. ICML 2025.

arxiv.org/abs/2503.18938 |
| 02 | LeCun. A Path Towards Autonomous Machine Intelligence. 2022.

openreview.net/pdf?id=BZ5a1r-kVsf | 07 | Huang et al. Vid2World: Crafting Video Diffusion Models to Interactive World Models. 2025 首发 .

arxiv.org/abs/2505.14357 |
| 03 | Yang et al. UniSim: Learning Interactive Real-World Simulators. ICLR 2024.

arxiv.org/abs/2310.06114 | 08 | Hafner et al. PlaNet: Learning Latent Dynamics for Planning from Pixels. ICML 2019.

arxiv.org/abs/1811.04551 |
| 04 | Wu et al. iVideoGPT: Interactive VideoGPTs are Scalable World Models. NeurIPS 2024.

arxiv.org/abs/2405.15223 | 09 | Hafner et al. Dream to Control: Learning Behaviors by Latent Imagination. ICLR 2020.

arxiv.org/abs/1912.01603 |
| 05 | Bruce et al. Genie: Generative Interactive Environments. ICML 2024.

arxiv.org/abs/2402.15391 | 10 | Zhou et al. DINO-WM: World Models on Pre-trained Visual Features Enable Zero-shot Planning. ICML 2025.

arxiv.org/abs/2411.04983 |





参考资料 2/2



正文页脚编号对应本页；演讲者备注附有完整来源。

- 11 Assran et al. V-JEPA 2: Self-Supervised Video Models Enable Understanding, Prediction and Planning. 2025.
arxiv.org/abs/2506.09985
- 12 Lu et al. ManiGaussian: Dynamic Gaussian Splatting for Multi-task Robotic Manipulation. ECCV 2024.
guanxinglu.github.io/ManiGaussian/
- 13 Barcellona et al. DreMa: Dream to Manipulate. ICLR 2025.
dreamtomanipulate.github.io/
- 14 Huang et al. PointWorld: Scaling 3D World Models for In-The-Wild Robotic Manipulation. 2026.
point-world.github.io/
- 15 World Labs. Marble: A Multimodal World Model. 2025.
www.worldlabs.ai/blog/marble-world-model
- 16 World Labs. Atlas: A World Model for Spatial Intelligence. 2026.
www.worldlabs.ai/blog/atlas
- 17 World Labs. A Functional Taxonomy of World Models. 2026.
www.worldlabs.ai/blog/taxonomy-of-world-models
- 18 Ding et al. Understanding World or Predicting Future? ACM Computing Surveys, 2025.
doi.org/10.1145/3746449
- 19 Li et al. A Comprehensive Survey on World Models for Embodied AI. 上传版本.
arxiv.org/abs/2510.16732





END

谢谢倾听
欢迎讨论

我对世界模型的理解

